OCTUBRE DE 2026

Amazon análisis — Proyecto de Portafolio BI

GUSTAVO VÁZQUEZ REYES

Contenido

Objetivo de negocio 1
Stakeholders 2
Preguntas de Negocio 3
Fuente de datos 3
Stack de herramientas 3
Problemas encontrados en los datos (Data Quality) 3
Proceso de limpieza y transformación 5
Modelo de datos 6
Preguntas de negocio que responde el dashboard 8
Detalle de métricas y tipo de gráficos usados 9
Dashboard 11
Hallazgos y recomendaciones 12
Conclusiones y próximos pasos 14

BI Professional: Gustavo Vázquez Reyes

Sponsor/ Stakeholder principal: Marcela Ibarra. Gerente de Categoría de Amazon

Propósito

Amazon es uno de los principales competidores en el negocio de marketplace, utiliza los descuentos como su principal palanca comercial para competir por atención y conversión. Sin embargo, hasta ahora no hay una estrategia definida basada en datos que confirme si realmente está generando el resultado esperado: relación entre el precio y los descuentos así como mayor satisfacción y mayor interés del cliente.

La base de datos analizada contiene un catálogo real de más de 1,000 productos con precio original, precio con descuento, rating y volumen de reviews por categoría que permite cuantificar esa relación en lugar de asumirla. Invertir en este análisis permitirá a la empresa dejar de aplicar descuentos de forma generalizada y en su lugar proteger margen donde no genera impacto, y redirigir recursos hacia las categorías donde sí lo haría.

Objetivo de negocio

Identificar qué categorías de productos combinan mejor precio/descuento con una mejor percepción de valor del cliente (rating) así mismo, identificar aquellas categorías que solo disminuyen el margen sin mejorar la satisfacción, con el fin de orientar la estrategia de descuentos y ajustes de pricing para el próximo trimestre.

Stakeholders

NOMBRE	PUESTO	DETALLES DE USO
Marcela Ibarra	Gerente de Categoría	Identificará qué categorías tienen "descuento alto / rating bajo" (foco de ajuste) vs. "descuento bajo / rating alto" (oportunidad de mantener margen).
Rodrigo Salcedo	Director Comercial	Consultará únicamente el resumen ejecutivo de forma trimestral, enfocado en el impacto general sobre el margen, sin necesidad de entrar al detalle técnico.
Daniela Peña	Analista de Pricing	Utilizará el nivel de detalle de product_id para ajustar precios puntuales en los casos identificados como ineficientes (alto descuento, bajo rating).
Julián Restrepo	Líder de Experiencia del Cliente	Se enfocará en las categorías y product_id con rating bajo, para priorizar mejoras de producto o de atención al cliente, independientemente del nivel de descuento aplicado.
Camila Torres	Product Owner del equipo de Datos/BI	Dará seguimiento a la calidad, actualización y mantenimiento técnico del dashboard, garantizando que la información que reciben los demás stakeholders sea confiable y esté al día.

Requisitos principales

- Gráfico de barras (reviews por categoría) + gráfico de dispersión (descuento promedio vs. rating promedio), con segmentador de categoría.

- Tarjetas KPI (rating promedio general, categoría con mejor relación descuento-rating, categoría con peor relación descuento-rating y total de reviews analizadas).

- Tabla detallada a nivel product_id, con columnas de precio original, precio descuento, % descuento y rating; filtrable y ordenable por categoría.

- Gráfico de barras de product_id ordenado de menor a mayor rating, filtrado a rating < 3.5, con volumen de reviews visible.

Preguntas de Negocio

¿En qué categorías se está perdiendo margen con descuentos que no mejoran la percepción del cliente?

¿El nivel de descuento aplicado está asociado con mejor o peor rating del producto, y varía esta relación entre categorías?

¿En qué categorías la brecha entre precio original y precio con descuento es mayor, y esas categorías realmente convierten esa oferta en más reviews/interés?

Fuente de datos

Base de datos: Amazon Sales Dataset
Origen: Kaggle https://www.kaggle.com/datasets/karkavelrajaj/amazon-sales-dataset/code
Tamaño: 1465 registros y 16 columnas

Stack de herramientas

Para este proyecto se utilizaron las siguientes herramientas de BI:

- SQLite + DBeaver: Almacenamiento, perfilado y limpieza vía SQL.
- CSV FILES: Validación cruzada y exploración rápida.
- Power BI: Modelado final y visualización (dashboard).

Problemas encontrados en los datos (Data Quality)

Dentro de esta base de datos se detectaron los siguientes errores e información faltante, por lo que se requiere la limpieza de los datos en SQL:

- Discounted_price y actual_price almacenados como texto, con caracteres especiales y comas de miles.

- Discount_percentage en formato texto con símbolo %.

- Registros con valor no numérico en rating.

- Rating_count en formato de texto, caracteres separados por comas de miles.

- Category como jerarquía concatenada con "|" en vez de columnas separadas. Se considera como categoría principal para este proyecto la cadena de datos que terminen con el primer símbolo "|".

- Columnas (user_id, user_name, review_id, review_content, etc.) con múltiples valores agregados por fila separados por coma, para este proyecto no se consideran estas columnas ya que son datos de tipo cualitativos no representativos para los objetivos de este proyecto.

Privacidad y Compliance

Los datos no deben incluir información de carácter personal, como nombre, dirección de correo electrónico, número de teléfono o dirección física. Aunque el usuario facilita estos datos al crear su cuenta y usuario en los campos user_id y user_name no son necesarios para este proyecto.

Cronograma

Para este proyecto se solicitó que el proceso en esta herramienta de BI se completara en un lapso de 6 semanas:

SEMANA	ALCANCE
Semana 1	Alineación de objetivos con stakeholders y asignación y revisión de conjunto de datos.
Semana 2- 3	Extracción y limpieza de datos en SQL y desarrollo de herramienta de ETL.
Semana 3- 4	Diseño de Dashboard en Power BI y revisión de visualizaciones de datos.
Semana 5- 6	Pruebas de funcionalidad de Dashboard, hallazgos y recomendaciones.

Proceso de limpieza y transformación

La limpieza y transformación de los datos se realizó directamente en SQLite, vía DBeaver, para la cual se ha creado una nueva tabla denominada amazon_clean_dataset. Se conservó sin modificaciones la tabla original para mantener los datos en crudo como respaldo si se detecta un nuevo error.

Las transformaciones aplicadas fueron:

Conversión de precios de texto a numérico: las columnas discounted_price y actual_price llegaban como texto con el símbolo de moneda (₹) y comas de miles (ej. "₹1,099"). Se usó REPLACE() anidado para eliminar ambos caracteres, y CAST(... AS REAL) para convertir el resultado a número real.

Conversión de porcentaje de descuento: discount_percentage venía como texto con el símbolo % (ej. "64%"). Se eliminó el símbolo y se dividió entre 100 para obtener un decimal (0.64), formato estándar para cálculos y gráficos de porcentaje en Power BI.

Extracción de categoría principal: la columna category contenía una jerarquía completa separada por | (ej. Computers&Accessories|Accessories&Peripherals|Cables). Se usó SUBSTR() + INSTR() para extraer únicamente el primer nivel como categoria_principal, conservando la jerarquía completa en una columna aparte (categoria_completa) por si se necesita en el futuro.

Exclusión de registros con rating inválido: se detectó un registro con un valor no numérico en rating (usando el patrón GLOB '*[^0-9.]*' para identificarlo). Los registros se excluyeron de la tabla mediante una cláusula WHERE, para evitar que rompiera el CAST a número.

Normalización de rating_count: se eliminaron las comas de miles y se convirtió a entero, para permitir sumas y agregaciones correctas.

Se anexa Script para la creación de la tabla amazon_clean_dataset:



Script
amazon_clean_data

https://github.com/GustavoVazqz/Amazon-dataset/blob/main/Script%20amazon_clean_dataset.txt

Modelo de datos

Para este proyecto se optó por un modelo de tabla única (sin esquema de estrella), en lugar de separar hechos y dimensiones en tablas distintas. La decisión se basa en que el dataset representa una sola entidad de negocio sin tablas transaccionales adicionales (como pedidos o clientes) que justificaran relaciones entre tablas.

La fuente conectada a Power BI es la vista amazon_clean_dataset; se extrajo de SQL como archivo CSV. Se modificaron directamente en Power BI los nombres de algunos campos:

Campo	Tipo	Descripción
product_id	Texto	Identificador de producto
product_name	Texto	Nombre y especificaciones del producto
category	Texto	Jerarquía de categoría (referencia)
Main_category	Texto	Jerarquía Principal de categoría
discounted_price_num	Decimal	Precio con descuento, numérico
actual_price_num	Decimal	Precio original, numérico
discount_pct	Decimal	Porcentaje de descuento
rating_num	Decimal	Calificación promedio del producto
rating_count_num	Entero	Número de reseñas del producto

Se agregaron métricas para realizar cálculos mediante medidas DAX directamente sobre esta tabla. Las fórmulas aplicadas son las siguientes:

Campo	DAX	Fórmula
Average Rating	AVERAGE	`Average Rating = AVERAGE(amazon_clean_dataset_202609092235[rating_num])`
AVG_Discount_pct	AVERAGE	`AVG_Discount_pct = AVERAGE(amazon_clean_dataset_202609092235[discount_pct])`
AVG_Discount_price_num	AVERAGE	`AVG_discount_price_num = AVERAGE(amazon_clean_dataset_202609092235[discounted_price_num])`
AVG_rating_count_num	AVERAGE	`AVG_rating_count_num = AVERAGE(amazon_clean_dataset_202609092235[rating_count_num])`

Categoria Mejor Relacion	VAR MAXX ALL AVERAGE RETURN CALCULATE SELECTEDVALUE FILTER	Categoria Mejor Relacion = VAR MejorRatio = MAXX(ALL(amazon_clean_dataset_202609092235[main_category]), [Valido]) RETURN CALCULATE(SELECTEDVALUE(amazon_clean_dataset_202609092235[main_category]), FILTER(ALL(amazon_clean_dataset_202609092235[main_category]), [Valido] = MejorRatio))
Categoria Peor Relacion	VAR MINX ALL RETURN CALCULATE SELECTEDVALUE FILTER	Categoria Peor Relacion = VAR PeorRatio = MINX(ALL(amazon_clean_dataset_202609092235[main_category]), [Valido]) RETURN CALCULATE(SELECTEDVALUE(amazon_clean_dataset_202609092235[main_category]), FILTER(ALL(amazon_clean_dataset_202609092235[main_category]), [Valido] = PeorRatio))
Ratio_Discount_Rating	DIVIDE	Ratio_Discount_Rating = DIVIDE([Average Rating], [AVG_Discount_pct])
Valido	IF DISTINCTCOUNT	Valido = IF(DISTINCTCOUNT(amazon_clean_dataset_202609092235[product_id]) >= 30, [Ratio_Discount_Rating])

Brecha_Precio_Pct	DIVIDE SUM	Brecha_Precio_Pct = DIVIDE(SUM(amazon_clean_dataset_202609092235[actual_price_num]) - SUM(amazon_clean_dataset_202609092235[discounted_price_num]), SUM(amazon_clean_dataset_202609092235[actual_price_num]))

Preguntas de negocio que responde el dashboard

A continuación se describe los gráficos y visualizaciones que ayudan a responder a las preguntas de negocio solicitadas por los stakeholders:

Pregunta de negocio	Visual que responde a la pregunta
¿En qué categorías se está perdiendo margen con descuentos que no mejoran la percepción del cliente?	Tarjeta peor categoría "Worst Category Disc./ Rating" y grafico de dispersión "Average rating vs Average Discount".
¿El nivel de descuento aplicado está asociado con mejor o peor rating del producto, y varía esta relación entre categorías?	Gráfico de dispersión "Average Rating vs Average Discount" tooltip. Tabla ordenada por discount_pct.
¿En qué categorías la brecha entre precio original y precio con descuento es mayor, y esas categorías realmente convierten esa oferta en más reviews/interés?	Gráfico de columnas agrupadas "Total Reviews per Category" y tooltip. Gráfico de dispersión "Average Rating vs Average Discount" tooltip

Detalle de métricas y tipo de gráficos usados

Gráfica 1 “Total Reviews per category”	Detalle
Tipo de Visualización	Gráfico de columnas agrupadas
Dimensión	Actual_price_num, AVG_discount_price_num, main_category; product_id, rating_count_num, Ratio Price and Discount
Métrica	Total de reviews por categoría

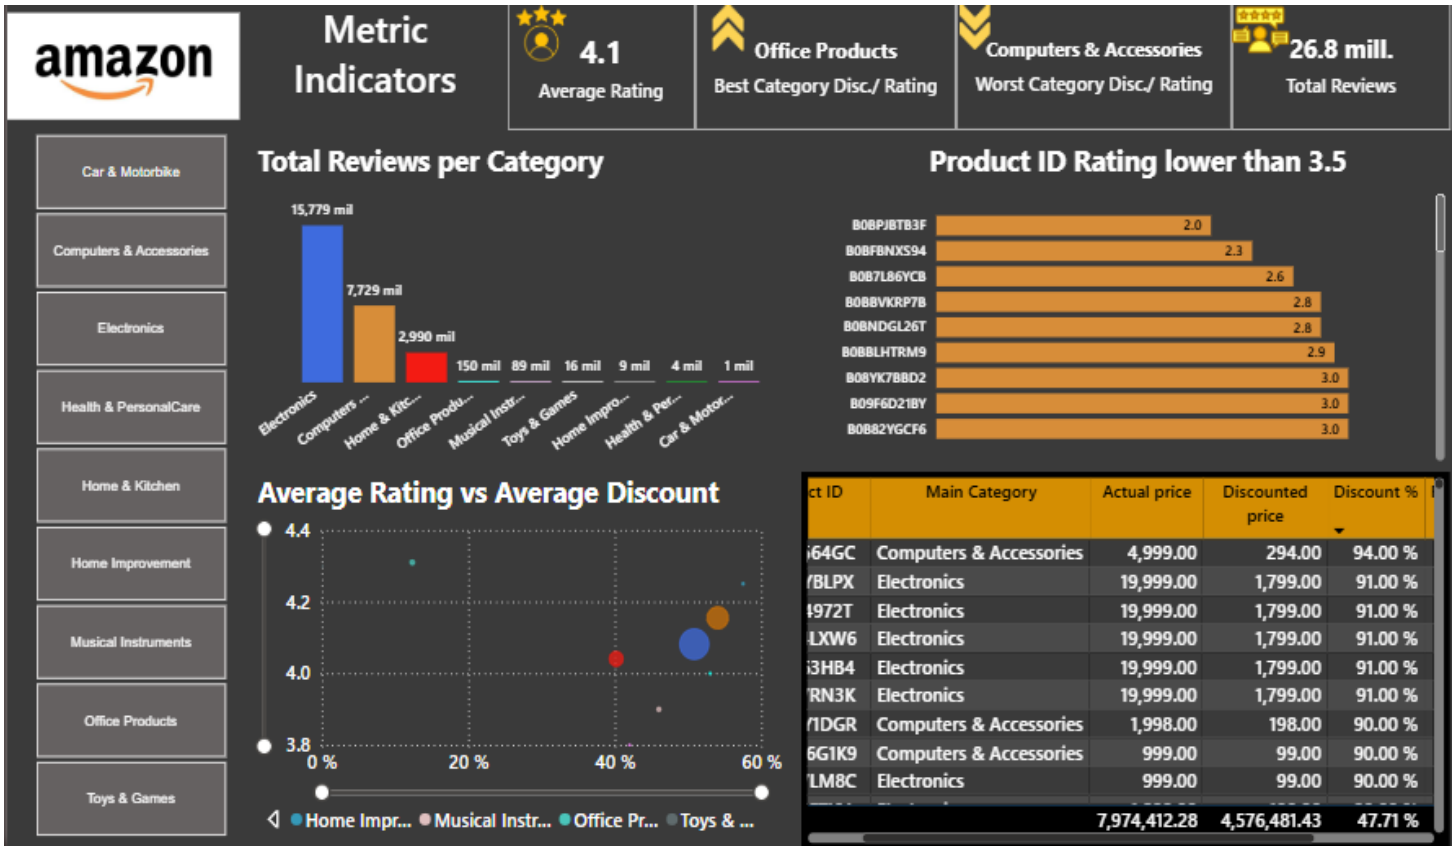
Gráfica 2 “Average Rating vs Average Discount”	Detalle
Tipo de Visualización	Gráfico de dispersión
Dimensión	Average Rating, AVG_Discount_pct, main_category, product_id, rating_count_num
Métrica	Relación descuento promedio y rating promedio por categoría

Gráfica 3 “Tarjetas KPI”	Detalle
Tipo de Visualización	Tarjeta
Dimensión	Average Rating, Categoria major relacion, Cataeogria Peor Relacion, rating_count_num
Métrica	Promedio de ratings, categoría con mejor relación descuento_rating, categoría con peor relación descuento-rating y total de reviews analizadas

Gráfica 4 “Detalle Product_ID”	Detalle
Tipo de Visualización	Tabla
Dimensión	Actual_price_num, discount_pct, discounted_price_num, main_category, product_id, rating_count_num, rating_num
Métrica	Detalle a nivel product_id filtrable por categoría

Gráfica 5 “Product ID Rating lower than 3.5”	Detalle
Tipo de visualización	Gráfico de barras agrupadas
Dimensión	main_category, product_id, rating_count_num, rating_num
Métrica	Total de Product_id con rating menores a 3.5

Dashboard



Se anexa acceso a enlace de publicación de reporte realizado en Power BI “Amazon Report.pbix” para su consulta o descarga:

https://github.com/GustavoVazqz/Amazon-dataset/blob/main/Amazon%20Report.pbix

Hallazgos y recomendaciones

Pregunta 1 — ¿En qué categorías se está perdiendo margen con descuentos que no mejoran la percepción del cliente?

A nivel de categorías “Computers&Accessories” (453) y “Electronics” (526) muestran los descuentos promedio más altos (54.0% y 50.8%) sin que esto se traduzca en una ventaja de rating frente a categorías con descuentos mucho menores: ya que como referencia la categoría “Office Products”, con solo 12.4% de descuento promedio, logra el rating más alto de todo el dataset (4.31). Esto sugiere que, entre las categorías con datos robustos, el descuento alto no mejora la percepción de valor. La recomendación es reducir gradualmente el margen de descuento en la categoría de menor eficiencia descuento-rating (“Computers&Accessories”) entre las de volumen representativo, y mantener la estrategia en “Electronics”, que logra el mayor volumen de reviews con una brecha menor. “Office Products” se toma como referencia de eficiencia, no como destino de recursos, por su tamaño (31 productos).

Adicionalmente hay 2 categorías que ameritan seguimiento y que no deben tomarse como tendencia de categoría por su bajo número de productos como la categoría “Musical Instruments” combina un descuento promedio del 46% con un rating de 3.9 y pese a tener solo 2 SKUs, concentra un volumen alto de reviews de 89K, lo que se traduce como una demanda real, candidata a ampliar variedad antes que a seguir descontando. Por otro lado está la categoría “Car & Motorbike” con un descuento del 42%, rating de 3.8 y apenas 1,118 reviews; aquí sí hay baja demanda real además de catálogo mínimo, por lo que el descuento parece no estar generando ni satisfacción ni tracción. En ambos casos puntuales se recomienda no aumentar más el descuento.

Pregunta 2 — ¿El nivel de descuento aplicado está asociado con mejor o peor rating del producto, y varía esta relación entre categorías?

A nivel producto no se observa una relación clara entre descuento y rating. Consultando la tabla (Gráfica 4) se observa que existen productos ID con más del 50% de descuento promedio y rating por debajo de 4, y otros con el mismo nivel de descuento pero rating superior a 4, es decir, el descuento por sí solo no explica la satisfacción del cliente. Sin embargo, al analizar a nivel categoría en el gráfico “Average Rating vs Average Discount” (Gráfica 2), sí aparecen patrones diferenciados siendo “Electronics” y “Computers & Accessories” las categorías que logran mantener un rating alto (>4) incluso con descuentos elevados, lo que sugiere que en esos casos el descuento no es la causa de una mayor satisfacción, sino que también hay relación con productos que son percibidos de buena calidad.

Pregunta 3 — ¿En qué categorías la brecha entre precio original y precio con descuento es mayor, y esas categorías realmente convierten esa oferta en más reviews/interés?

Al consultar el detalle dentro del tooltip de la tabla de dispersión "Avergae Rating vs Average Discount" podemos observar que "Computers & Accessories" es la categoría representativa que mayor brecha tiene entre el precio y el descuento, ya que concentra una diferencia del 50% sobre el precio original, y es la segunda categoría con más reviews (7.73M). Sin embargo, al compararla con "Electronics", la categoría mejor posicionada en reviews (15.7M) dobla el número de reviews de "Computers & Accessories" pero con una diferencia de apenas el 41% relación precio- descuento.

Por lo anterior se recomienda evaluar una reducción más conservadora de descuentos en la categoría "Computers & Accessories", ya que la brecha actual Precio- Descuento no se traduce en un mayor número de reviews.

Limitaciones

Muestra

El dataset presenta una distribución muy desigual del número de registros de product_id por categoría: mientras "Electronics" (526) y "Computers&Accessories" (453) concentran la mayoría del catálogo, categorías como "Car & Motorbike" (1 producto), "Musical Instruments" (2), "HomeImprovement" (2), "Health&PersonalCare" (1) y "Toys&Games" (1) cuentan con muestras demasiado pequeñas para sostener conclusiones confiables a nivel categoría.

Temporalidad

Se encontró que dentro de este dataset no se contemplan fechas que sugieran algún patrón o tendencia de periodicidad que pudiera afectar los resultados obtenidos, por lo que más adelante se sugiere contemplar estos datos para tener una mejor precisión en cuanto a las estrategias a desarrollar.

Ventas

El dataset no incluye datos de ventas ni ingresos. El número de reviews (rating_count) se utilizó como variable del interés o consumo del cliente, lo cual es una aproximación razonable pero no equivale a volumen de ventas confirmado que ayude a determinar patrones estratégicos para la toma de decisiones.

Conclusiones y próximos pasos

Con base en la información presentada en este dataset , ofrecer mayores descuentos no se traduce a un mejor rating ni con un mayor volumen de reviews. Entre las categorías con un volumen representativo es “Office Products”, la cual muestra la mayor eficiencia: el rating más alto (4.31) con solo 12.4% de descuento promedio, aunque su catálogo es pequeño (31 productos) y debe tomarse como referencia y no como destino de recursos.

Como recomendación es mejor enfocarse en productos específicos, independientemente de su categoría bajo los siguientes criterios: rating mayor a 4, alto volumen de reviews y descuentos moderados para definir mejor los rangos de descuento.

Adicional se recomienda revisar de forma gradual la estrategia de descuentos de la cateogria “Computers & Accesories” ya que de acuerdo con los gráficos es la peor categoría en relación descuentos y ratings (54.0% de descuento promedio y 50% de brecha de precio, con rating de 4.15) y, al ser la segunda con más product_id (453) y reviews (7.73M); por lo que descuidar los product_id en esta categoría podría reducir considerablemente los reviews y el rating aún y cuando los productos tengan un mejor descuento, adicional se sugiere monitorear esta información periódicamente, por lo que en el futuro es necesario relacionar esta información con informes de ventas.

En otras categorías como “Electronics” se sugiere mantener la estrategia actual. Las categorías con muestra insuficiente (como “Musical Instruments” y “Car & Motorbike”) deben monitorearse hasta contar con más productos (counsultar Limitaciones pag.13).

Complementar este dataset con fechas para detectar tendencias que ayuden a definir en qué meses es conveniente aumentar o reducir volumen de descuentos con ventas por periodo; y con costos o márgenes por producto, para validar si sostener el descuento es rentable frente a la meta de ingresos de la compañía.